

Pré-registro da análise da 2ª codificação cega

Escrito em: 27 de julho de 2026, **antes** de a anotação ser executada. **Autor:** Randerson O. M. Rebouças **Propósito:** fixar, antes de ver qualquer número, o que será reportado no artigo em cada cenário de resultado. Sem isso, escolher a forma de relato depois de conhecer o κ é escolha conveniente, e é o tipo de coisa que um revisor atento identifica.

Este documento é citável na *response letter* e vai junto com o material aberto do estudo.

1. O que está sendo medido

Duas análises independentes sobre as mesmas 39 saídas do qwen2.5:3b-instruct:

- (A) Confiabilidade da codificação das funções de mediação (Tabela 9 do artigo).** Concordância entre o anotador 1 (codificação embutida em `analises/fm_coding_model.py`, codebook v0.2) e o anotador 2 (passada cega), por função FM01 a FM08.
- (B) Validade de construto da métrica da RQ2.** Concordância entre a régua lexical de palavra-chave (`src/metalinguistic_adherence.py`) e o julgamento especialista registrado na coluna MTL.

2. Estatísticas a reportar (decidido antes da coleta)

Para as duas análises:

- κ **de Cohen por categoria**, com bandas de Landis & Koch (1977).
- **Concordância bruta (%)** ao lado de cada κ , sempre, não só quando conveniente.
- **Prevalência observada em cada anotador**, para o leitor julgar por si.
- Nas categorias com base rara ou saturada (na passada do anotador 1: FM01 em 39/39, FM05, FM06 e FM08 em 0/39), acrescentar **PABAK** (Byrt et al., 1993) e sinalizar explicitamente que o κ é degenerado ali, citando o paradoxo do κ (Feinstein & Cicchetti, 1990). **Não** substituir o κ pelo PABAK: reportar os dois lado a lado.

Nenhuma categoria será omitida da tabela por ter resultado ruim.

3. Regra de relato da análise (A), confiabilidade das FMs

Resultado	O que vai para o artigo
κ médio $\geq 0,61$ (substantial ou acima)	Tabela 9 mantida como está, agora com o vetor de κ da v0.2 reportado ao lado.
κ médio entre 0,41 e 0,60	Tabela 9 mantida, com a confiabilidade reportada e uma ressalva explícita de que a leitura função-a-função é indicativa; a conclusão passa a se apoiar no padrão agregado (ausência do núcleo corretivo), não nos percentuais individuais.

Resultado	O que vai para o artigo
κ médio < 0,41, ou κ < 0,40 em FM02, FM04 ou FM06	As três funções que sustentam a conclusão perdem o estatuto de evidência quantitativa. A Tabela 9 é rebaixada a ilustração qualitativa, os percentuais saem do <i>abstract</i> e da conclusão, e o achado é reformulado como observação de padrão, não como medida.

Em qualquer um dos três casos os números são publicados.

4. Regra de relato da análise (B), validade da métrica da RQ2

Resultado	O que vai para o artigo
$\kappa \geq 0,61$	A régua lexical é reportada como proxy validado do construto. A taxa de 51,3% deixa de ser "triagem indicativa" e passa a medida com validade de construto estabelecida, sempre acompanhada do κ .
κ entre 0,41 e 0,60	A régua permanece sonda corroborativa , exatamente como o artigo já a trata hoje, agora com a limitação quantificada em vez de declarada. Reporto lado a lado a taxa da régua (51,3%) e a taxa do julgamento humano, e discuto a diferença.
$\kappa < 0,41$	A régua lexical é declarada inadequada como medida do construto . A taxa de 51,3% sai do <i>abstract</i> e da conclusão. Em seu lugar entra a taxa obtida pelo julgamento especialista sobre as 39, que passa a ser a evidência da RQ2, com n e intervalo de Wilson. O achado da RQ2 não desaparece: muda de instrumento.

Compromisso explícito: a definição da coluna MTL está congelada no GUIA_2a_CODIFICACAO.md desta mesma data e **não será ajustada depois de ver os resultados**. Se ela se mostrar mal formulada, isso é reportado como limitação, não corrigido retroativamente.

5. Limitações já assumidas, a declarar no artigo

- **Juiz único.** A análise (B) confronta a régua com o julgamento de um especialista, não de um painel. O Revisor A pediu "independent human evaluation", não painel, mas a limitação é registrada.
- **Anotador coautor.** O segundo anotador é um dos autores, especialista em Educação, cego à codificação anterior e à ordem original. Isso passa a ser dito explicitamente no §7.4, no lugar da formulação atual ("a second, blind, and independent annotator"), e acrescentado ao CRediT.
- **Duas passadas separadas.** As colunas FM e MTL são preenchidas em varreduras distintas, para reduzir o arrasto de uma sobre a outra, mas pelo mesmo anotador. A independência entre os dois julgamentos é, portanto, parcial.

- **Viés de formato.** O esquema de saída do modelo força um movimento de reconhecimento

(FM01) e abre espaço para reflexão e ampliação, o que já está discutido no §7.5 e continua valendo na leitura dos novos números.

6. O que não muda

As análises acima tocam apenas a RQ2 e a seção de referência especialista. Os achados estruturais da RQ1 (312 chamadas primárias, o contraste 39/39 contra 0/39 na família Llama 3.2, o protocolo de falsificação e os testes de Fisher) são independentes desta codificação e não são afetados por nenhum dos cenários acima.